☐ CoderWanFeng / python-office Public

update readme.md Browse files P master liuzf1 committed 43 minutes ago1 parent 901cee4 commit 7217772473080aa5673b029b67f5c9929d8e0385

Showing 7 changed files with 124 additions and 118 deletions.

Split Unified

√ · † 2 ■■■■ .gitignore □						
27	MANIFEST	27	MANIFEST			
28		28				
29		29				
30	- # CoderWanFeng	30	+ # <u>demo</u>			
31	.idea/	31	.idea/			
32	.gitee/	32	.gitee/			
33	shell/upload.sh	33	shell/upload.sh			

V 17 ■■■■ README.md □						
117		117				
118	python-office欢迎任何人来添砖加瓦,贡献代	118	python-office欢迎任何人来添砖加瓦,贡献代			
	码,建议提交的pr (pull request)符合一些规		码,建议提交的pr (pull request) 符合一些规			
	范,规范如下:		范,规范如下:			
119		119				
120	- 0. 每位参与者,请在文件夹: ./contributors	120	+ 参与项目建设的步骤:			
	下,以自己的GitHub账号为名称,建立自己的py					
	文件夹,在其中进行创作。不要修改自己文件夹以					
	外的任何文件。					
121	例如:我需要给python-office添加一个	121	+ - 例如: 你需要给python-office添加一个add方			
	add方法。		法。			
122	- 我的Github账户名	122	+ 1. 你的Github账户名为: demo			
	为: CoderWanFeng。					
123	于是我在./contributors新建了文	123	+ 2. 于是你在./contributors新建了文件夹.			
	件夹./CoderWanFeng后,		/demo			
124	新建了add.py文件,编辑我的代码	124	+ 3. 新建了add.py文件,编辑你的代码			

第1页 共11页 2022/5/17 下午 3:18

		125	+ 4.编辑完成,提交pr到master分支(gitee 或者GitHub,都可以)。可以注明你对自己功能的取名建议
		126	+ 5. 晚枫收到后,会对各位的代码进行测试
			后,合并后打包上传到python官方库
		127	+
		128	+ ### ▶代码规范
		129	+
125	1. 注释完备,尤其每个新增的方法应按照Google	130	1. 注释完备,尤其每个新增的方法应按照Google
	Python文档规范标明方法说明、参数说明、返回		Python文档规范标明方法说明、参数说明、返回
	值说明等信息,必要时请添加单元测试,如果愿		值说明等信息,必要时请添加单元测试,如果愿
	意,也可以加上你的大名。		意,也可以加上你的大名。
126	- 2. python-office的文档,需要进行格式化。注	131	+ 2. python-office的文档,需要进行格式化。注
	意: 只需要格式化你自己的代码		意: 只能格式化你自己的代码
127	3. 请直接pull request到`master`分支。	132	3. 请直接pull request到`master`分支。
	`master`是主分支,表示已经发布pypi库的版		`master`是主分支,表示已经发布pypi库的版
	本。**未来参与人数增多,会开辟新的分支,请		本。**未来参与人数增多,会开辟新的分支,请
	留意本文档的更新。**		留意本文档的更新。**
128	4. 我们如果关闭了你的issue或pr,请不要诧	133	4. 我们如果关闭了你的issue或pr,请不要诧
	异,这是我们保持问题处理整洁的一种方式,你依		异,这是我们保持问题处理整洁的一种方式,你依
	旧可以继续讨论,当有讨论结果时我们会重新打		旧可以继续讨论,当有讨论结果时我们会重新打
	开。		开。
129		134	

√ 111 ■■■■ contributors/ CNSeniorious000/pdf.py □

... @@ -0,0 +1,111 @@

```
+ # from functools import cache,
      cached_property
 2
    + # # PDF与栅格化
5
    + # # noinspection PyPackageRequirements
    + # class PDF:
 7
    + # a pdf document with optimized lazy
      processing
            @Author & Date: CNSeniorious000
      2022/5/17
10
11
    + #
12
    + # @cache
13
    + #
          def __new__(cls, *args, **kwargs):
```

第2页 共11页

```
14
                 """a path refers to only one
       document"""
15
                 return object.__new__(cls)
16
     + #
17
             def __init__(self, path: str):
18
     + #
                 """load from disk or
       internet"""
19
                 if path.startswith("http"):
20
                    import requests
21
                     self.raw =
       requests.get(path).content
22
                 else:
23
     + #
                     self.raw = open(path,
       "rb").read()
24
25
     + #
             @cached_property
26
             def doc(self):
27
     + #
                 import fitz
28
                 # noinspection
       PyUnresolvedReferences
29
                 return
       fitz.open(stream=self.raw)
30
31
     + #
             @property
32
           def page_count(self):
33
                 return self.doc.page_count
34
     + #
35
     + #
             @cache
36
             def get_pixmap(self, page=0,
       dpi=108, alpha=True):
37
    + #
                 return
       self.doc[page].get_pixmap(dpi=dpi,
       alpha=alpha)
38
     + #
39
     + #
             @cache
40
             def get_image(self, *args,
       **kwargs):
41
                 from imageio import imread
42
     + #
                 from numpy import asarray
43
                 return
       asarray(imread(self.get_pixmap(*args,
       **kwargs).tobytes()))
44
    + #
```

```
45
             @staticmethod
46
     + #
             def show(image):
47
                 from matplotlib.pyplot import
       imshow, show
48
                 imshow(image)
49
     + #
                 return show()
50
51
     + # def show_image(self, *args,
       **kwargs):
52
                 return
       self.show(self.get_image(*args,
       **kwargs))
53
    + #
54
     + # def save_image(self, file_path:
       str, page=0, dpi=144, alpha=True):
55
                return self.get_pixmap(page,
      dpi, alpha).save(file_path)
56
     + #
57
    + # def save_images(self, dir_path:
       str, pages=..., dpi=144, alpha=True,
       encode="png", show_bar=True):
58
               if not
      os.path.isdir(dir_path):
59
                    os.mkdir(dir_path)
60
61
                it = range(self.page_count) if
       pages is ... else pages
62
63
               if show_bar:
64
                    from alive_progress import
       alive_it
65
     + #
                     it = alive_it(it)
66
67
     + #
               for page in it:
68
                    self.save_image(f"
       {dir_path}/{page}.{encode}", page, dpi,
       alpha)
69
     + #
70
     + #
71
    + # # PDF与OCR
72
     + # class PDFReader(PDF):
73
     + # def __init__(self, path: str,
       lang=("en", "ch_sim")):
```

```
74
                  super().__init__(path)
 75
      + #
                  self.lang = lang
 76
      + #
 77
      + #
              @cached_property
 78
              def reader(self):
 79
      + #
                  from easyorr import Reader
 80
      + #
                  return Reader(self.lang)
 81
      + #
 82
      + #
              @cache
 83
              def get_texts(self, page=0, *args,
        **kwargs):
 84
                  return
        self.reader.readtext(self.get_image(page
        , *args, **kwargs))
 85
      + #
 86
              def render_bbox(self, page=0,
        *args, color=(255, 0, 0), **kwargs):
 87
                 from cv2 import line
 88
                  image = self.get_image(page,
        *args, **kwargs).copy()
 89
                 for points, string, degree in
        self.get_texts(page, *args, **kwargs):
 90
                      c = (*color, round(degree
        * 255))
 91
                      # noinspection
        PyPep8Naming
 92
     + #
                      A, B, C, D =
        [tuple(map(round, point)) for point in
        points]
 93
                      line(image, A, B, c)
 94
      + #
                      line(image, B, C, c)
 95
      + #
                      line(image, C, D, c)
 96
                      line(image, D, A, c)
 97
      + #
 98
      + #
                  return image
 99
      + #
100
              def show_image_with_bbox(self,
        *args, **kwargs):
101
                  return
        self.show(self.render_bbox(*args,
        **kwargs))
102
     + #
```

```
103
             def classify(self, choices,
       page=0, *args, **kwargs):
104
105
                这个函数的功能在于, 比如有一个奖
     + #
       状,上面可能有一等奖二等奖三等奖,要批量识别
       出一张图片为什么奖
106
                :param page: the page to ocr
107
     + #
                :param choices: list or words
       to choose
108
     + #
109
     + #
                from rapidfuzz.process import
       extractOne
110
                texts = [string for _, string,
       _ in self.get_texts(page, *args,
       **kwargs)]
111
                return
       sorted((extractOne(choice, texts)[1],
       choice) for choice in choices)[-1][1]
```

File renamed without changes.

```
✓ 0 □□□□□ contributors/CoderWanFeng/add.py → contributors/demo/demo.py □□
```

File renamed without changes.

```
59
                                            59
60
                                            60
      def add_watermark(file, mark,
                                                  def add_watermark(file, mark,
      out="output", color="#8B8B1B", size=30,
                                                  out="output", color="#8B8B1B", size=30,
      opacity=0.15, space=75, angle=30):
                                                  opacity=0.15, space=75, angle=30):
61
                                            61
62
                                            62
         @Author & Date : CoderWanFeng
                                                      @Author & Date : demo 2022/5/6 14:33
      2022/5/6 14:33
                                            63
63
         @Desc : 给图片添加水印
                                                      @Desc : 给图片添加水印
64
         @Return : 添加了水印的图片,输出到out
                                                      @Return : 添加了水印的图片,输出到out
      指定的文件夹
                                                   指定的文件夹
65
                                            65
```

```
6
 6
       from PyPDF2 import PdfFileReader,
                                                          from PyPDF2 import PdfFileReader,
       PdfFileWriter
                                                          PdfFileWriter
 7
                                                    7
       from pdf2docx import Converter
                                                          from pdf2docx import Converter
 8
                                                    8
 9
       # from functools import cache,
       cached_property
10
                                                    9
11
                                                   10
       #给pdf加水印
                                                          #给pdf加水印
12
       def add_watermark():
                                                   11
                                                          def add_watermark():
82
                                                   81
               cv.close()
                                                                  cv.close()
83
                                                   82
           except:
                                                              except:
84
                                                   83
               print('这个文件有问题~!')
                                                                  print('这个文件有问题~!')
85
86
      - # # PDF与栅格化
87
      - # # noinspection PyPackageRequirements
88
      - # class PDF:
89
     - #
             ....
90
             a pdf document with optimized lazy
       processing
91
             @Author & Date: CNSeniorious000
       2022/5/17
92
             ....
93
      - #
94
     - #
             @cache
95
     - #
             def __new__(cls, *args, **kwargs):
96
                 """a path refers to only one
       document"""
97
                 return object.__new__(cls)
98
99
      - #
             def __init__(self, path: str):
100
                 """load from disk or
       internet"""
101
                 if path.startswith("http"):
102
     - #
                     import requests
103
                     self.raw =
       requests.get(path).content
104
     - #
                 else:
105
                     self.raw = open(path,
       "rb").read()
106
107
             @cached_property
```

```
108
              def doc(self):
109
                  import fitz
110
                  # noinspection
        PyUnresolvedReferences
111
                  return
        fitz.open(stream=self.raw)
112
113
      - #
              @property
114
              def page_count(self):
115
                  return self.doc.page_count
116
      - #
117
      - #
              @cache
118
              def get_pixmap(self, page=0,
        dpi=108, alpha=True):
119
                  return
        self.doc[page].get_pixmap(dpi=dpi,
        alpha=alpha)
120
      - #
121
      - #
              @cache
122
              def get_image(self, *args,
        **kwargs):
123
                  from imageio import imread
124
                  from numpy import asarray
125
                  return
        asarray(imread(self.get_pixmap(*args,
        **kwargs).tobytes()))
126
127
              @staticmethod
128
              def show(image):
129
                  from matplotlib.pyplot import
        imshow, show
130
                  imshow(image)
131
                  return show()
132
133
              def show_image(self, *args,
        **kwargs):
134
                  return
        self.show(self.get_image(*args,
        **kwargs))
135
136
              def save_image(self, file_path:
        str, page=0, dpi=144, alpha=True):
```

```
137
                  return self.get_pixmap(page,
        dpi, alpha).save(file_path)
138
139
              def save_images(self, dir_path:
        str, pages=..., dpi=144, alpha=True,
        encode="png", show_bar=True):
140
                 if not
        os.path.isdir(dir_path):
141
                     os.mkdir(dir_path)
142
143
                  it = range(self.page_count) if
        pages is ... else pages
144
145
                  if show_bar:
146
                      from alive_progress import
       alive_it
147
                      it = alive_it(it)
148
149
      - #
                 for page in it:
150
                      self.save image(f"
        {dir_path}/{page}.{encode}", page, dpi,
        alpha)
151
      - #
152
      - #
153
      - # # PDF与OCR
154
      - # class PDFReader(PDF):
155
          def __init__(self, path: str,
        lang=("en", "ch_sim")):
156
                  super().__init__(path)
157
                  self.lang = lang
158
      - #
159
              @cached_property
160
            def reader(self):
161
                  from easyocr import Reader
162
                  return Reader(self.lang)
163
      - #
164
              @cache
165
              def get_texts(self, page=0, *args,
        **kwargs):
166
                 return
        self.reader.readtext(self.get_image(page
        , *args, **kwargs))
167
```

```
168
          def render_bbox(self, page=0,
       *args, color=(255, 0, 0), **kwargs):
169
               from cv2 import line
170
               image = self.get_image(page,
       *args, **kwargs).copy()
171
               for points, string, degree in
      self.get_texts(page, *args, **kwargs):
172
                   c = (*color, round(degree
       * 255))
173
                    # noinspection
       PyPep8Naming
174
                    A, B, C, D = 
       [tuple(map(round, point)) for point in
       points]
175
                    line(image, A, B, c)
176
                    line(image, B, C, c)
177
                    line(image, C, D, c)
178
                    line(image, D, A, c)
179
180
      - #
                return image
181
182
           def show_image_with_bbox(self,
       *args, **kwargs):
183
               return
       self.show(self.render_bbox(*args,
       **kwargs))
184
     - #
185
     - # def classify(self, choices,
       page=0, *args, **kwargs):
186
187
                这个函数的功能在于, 比如有一个奖
       状,上面可能有一等奖二等奖三等奖,要批量识别
       出一张图片为什么奖
188
                 :param page: the page to ocr
189
                 :param choices: list or words
       to choose
190
191
               from rapidfuzz.process import
       extractOne
192
      - # texts = [string for _, string,
       _ in self.get_texts(page, *args,
       **kwargs)]
```

0 comments on commit 7217772

第11页 共11页 2022/5/17 下午 3:18